



**CIENCIAS  
E INGENIERÍA  
CAYETANO**

# **Comparación de algoritmos de segmentación para la detección de cáncer de mama a partir de imágenes de ultrasonido**

**Autores:**

Alessandra Aldave Javier

Valeria Zavaleta Jave

**LIMA - PERÚ 2024**

# ÍNDICE

<b>1. Introducción.....</b>	<b>3</b>
<b>2. Marco Teórico.....</b>	<b>4</b>
2.1. Ultrasonido mamario.....	4
2.2. Segmentación de imágenes.....	5
2.3. Clasificación de tumores.....	5
2.4. Aprendizaje profundo.....	6
2.5. Extracción de características radiómicas.....	6
<b>3. Objetivos del proyecto.....</b>	<b>6</b>
3.1. Objetivo General.....	6
3.2. Objetivos Específicos.....	6
<b>4. Materiales y métodos.....</b>	<b>7</b>
4.1. Metodología.....	7
4.2. Consideraciones éticas.....	11
<b>5. Cronograma.....</b>	<b>11</b>
<b>6. Presupuesto.....</b>	<b>12</b>
<b>7. Referencias.....</b>	<b>12</b>

# 1. Introducción

Por muchos años y hasta la actualidad, el cáncer de mama constituye uno de los más grandes desafíos de salud pública a nivel mundial [1][2], en donde el 99% de los casos de cáncer de mama se presentan en mujeres y entre 0.5% a 1%, en hombres [3].

El cáncer de mama se caracteriza por ser una enfermedad en la cual las células que pertenecen al tejido mamario se encuentran en un proceso de crecimiento sin control [4]. Cuando el diagnóstico de esta enfermedad se realiza de manera temprana, las probabilidades de éxito que se puede conseguir con el tratamiento son altas; no obstante, si la detección es tardía, el porcentaje de proliferación de células tumorales resulta elevado, lo cual sitúa la condición de la paciente en el último estadio del cáncer de seno (estadio IV) [5] en el cual, el cáncer inicialmente concentrado en las mamas se disemina hacia otras áreas del cuerpo conduciendo a un cáncer metastásico que, pese a que puede ser tratado, permanece incurable [6].

A nivel global, las cifras son alarmantes: en el año 2020 se diagnosticaron aproximadamente 2.26 millones de nuevos casos de cáncer de mama, lo que lo posiciona como la quinta causa principal de muerte en mujeres, con 685,000 fallecimientos registrados [7]. En el 2022, el cáncer de mama ha sido el tipo de cáncer más común en mujeres en 157 países de 185, y en el mismo año, esta enfermedad produjo 670 000 muertes a nivel global [3]. Sin embargo, persisten desigualdades significativas en la distribución de la enfermedad. En países con un muy alto Índice de Desarrollo Humano, 1 de cada 12 mujeres son diagnosticadas y 1 en 71 mujeres mueren por cáncer de mama. En contraste, en países con bajo IDH, únicamente 1 de cada 27 mujeres son diagnosticadas con cáncer de mama y se estima que 1 de cada 48 mujeres morirán bajo esta causa [3].

En el contexto peruano, la situación no es menos preocupante. El cáncer de mama es el tipo más común de cáncer entre las mujeres peruanas [8]. Además, con una incidencia en constante aumento, se registran alrededor de 28 casos nuevos por cada 100,000 habitantes cada año, reflejando una tendencia preocupante en las últimas dos décadas [9].

En este escenario, la detección temprana emerge como un factor crucial para mejorar las tasas de supervivencia. El diagnóstico precoz del cáncer de mama no solo aumenta las posibilidades de cura al detectar la enfermedad en etapas más tempranas, cuando el tumor es más tratable, sino que también abre la puerta a opciones de tratamiento menos invasivas, preservando así la calidad de vida de las pacientes [10]. Además, un

diagnóstico oportuno se traduce directamente en una reducción de la mortalidad asociada a la enfermedad, salvando vidas y mejorando el pronóstico general.

De esta manera, se destaca la relevancia de la implementación de tecnologías innovadoras como algoritmos predictivos para la detección temprana del cáncer de mama a partir de imágenes de ultrasonido mamario. Este tipo de avances representan una alternativa para mejorar la precisión del diagnóstico, agilizar el proceso diagnóstico y facilitar el acceso a este crucial servicio de salud, especialmente en áreas con recursos limitados o acceso deficiente a servicios especializados.

## **2. Marco Teórico**

### **2.1. Ultrasonido mamario**

El ultrasonido mamario o ultrasonido de seno, una técnica no invasiva y altamente versátil en el ámbito médico, desempeña un papel integral en el diagnóstico y seguimiento de patologías mamarias. Su funcionamiento se basa en el principio piezoeléctrico, donde un transductor emite ondas sonoras de alta frecuencia que atraviesan los tejidos mamarios y se reflejan de manera diferencial, dependiendo de la composición y características de dichos tejidos. Estas señales reflejadas son detectadas por el transductor y luego procesadas por un sistema encargado de generar imágenes detalladas en escala de grises, ofreciendo una representación visual del interior de la mama [11].

La utilidad del ultrasonido mamario abarca diversas áreas. En primer lugar, es ampliamente empleado para la detección y caracterización de nódulos mamarios. Su capacidad para identificar incluso las lesiones más pequeñas y sutiles, así como su habilidad para diferenciar entre masas sólidas y quísticas, lo convierten en una herramienta invaluable en el diagnóstico precoz de enfermedades mamarias [12]. Además, el ultrasonido mamario se utiliza en la evaluación de anomalías detectadas en mamografías o resonancias magnéticas mamarias, proporcionando información adicional que puede ser crucial para el tratamiento y manejo de la enfermedad.

Otro aspecto crucial es su utilidad como guía en procedimientos invasivos, como biopsias. El ultrasonido mamario permite una visualización en tiempo real de la ubicación exacta del tejido anormal, lo que facilita la obtención de muestras precisas para análisis patológicos [13]. Además, su papel en la detección complementaria del cáncer de seno es invaluable, especialmente en casos donde la mamografía puede resultar limitada, como en senos densos [11].

## **2.2. Segmentación de imágenes**

La segmentación de imágenes es un proceso fundamental en el análisis de imágenes digitales, que consiste en dividir una imagen en sus componentes constituyentes [14]. En el contexto del cáncer de mama, se utiliza para identificar los límites de un tumor en una imagen de ultrasonido.

Los objetivos de la segmentación de imágenes son extraer información relevante, como separar los objetos de interés del fondo y de otros objetos, cuantificar características como tamaño, forma y textura, y facilitar el análisis posterior para otras tareas de procesamiento de imágenes [15].

Existen varios métodos de segmentación de imágenes, incluyendo la segmentación basada en umbrales, que establece un umbral de intensidad de píxeles para clasificarlos como parte del objeto de interés o del fondo [16]; la segmentación basada en bordes, que detecta los bordes de los objetos en la imagen para definir los límites del objeto de interés; la segmentación basada en regiones, que agrupa píxeles con características similares en regiones que representan los objetos de interés [17]; y la segmentación basada en aprendizaje automático, que utiliza algoritmos de aprendizaje automático para aprender a segmentar objetos en imágenes a partir de ejemplos [18].

## **2.3. Clasificación de tumores**

La clasificación de imágenes basada en etiquetas constituye un proceso esencial en el ámbito del aprendizaje automático, donde su objetivo primordial radica en la asignación de etiquetas o categorías específicas a las imágenes de interés [19]. En el contexto del cáncer de mama, este proceso adquiere una relevancia crucial al ser utilizado para discernir si un tumor identificado en una imagen es benigno o maligno, lo cual es fundamental para la toma de decisiones clínicas.

Los objetivos fundamentales de la clasificación de imágenes basada en etiquetas se dividen en varias etapas. En primer lugar, se busca asignar de manera precisa y correcta las etiquetas correspondientes a las imágenes, lo que implica que el modelo de clasificación aprenda a asociar de forma adecuada cada imagen con su respectiva categoría. Además, se busca que el modelo sea capaz de generalizar a nuevas imágenes, es decir, que pueda clasificar correctamente imágenes que no haya visto previamente durante el entrenamiento [19]. Asimismo, se busca que el modelo sea robusto frente a variaciones en las condiciones de captura de las imágenes, como variaciones en la iluminación, el ángulo de visión y otras condiciones que puedan afectar la apariencia de las mismas [20].

## **2.4. Aprendizaje profundo**

El aprendizaje profundo es una subárea del aprendizaje automático que emplea redes neuronales artificiales con múltiples capas para aprender características complejas de los datos, simulando la manera de aprendizaje de un cerebro humano [21]. Estas redes han demostrado resultados sobresalientes en diversas tareas de clasificación e identificación de imágenes, como el desarrollo de sistemas de reconocimiento facial, vehículos autónomos y sistemas de vigilancia inteligente [22].

Las arquitecturas más comunes incluyen las redes neuronales convolucionales (CNNs), efectivas para análisis de imágenes; las redes neuronales recurrentes (RNNs), útiles para procesamiento de secuencias de datos; y las redes neuronales profundas convolucionales recurrentes (CNN-RNNs), que combinan ambas. Los beneficios del aprendizaje profundo incluyen mayor capacidad de aprendizaje, mejor rendimiento y mayor flexibilidad en la adaptación a diversas tareas y aplicaciones [8].

## **2.5. Extracción de características radiómicas**

Las características radiómicas se refieren a un conjunto de características cuantitativas extraídas de imágenes médicas, como resonancias magnéticas, tomografías computarizadas o imágenes de rayos X. Estas características capturan información sobre la forma, textura, intensidad y distribución de los píxeles en una imagen, entre otros aspectos [23]. La extracción y análisis de características radiómicas pueden ayudar en la detección, diagnóstico, pronóstico y seguimiento de enfermedades como el cáncer.

# **3. Objetivos del proyecto**

## **3.1. Objetivo General**

Desarrollar un prototipo con interfaz de usuario (UI) que permita realizar análisis de imágenes de ultrasonido (US) de cáncer de mama en tiempo real haciendo uso de modelos *Deep Learning* y *Machine Learning* para la segmentación de imágenes y clasificación de tumores benignos y malignos, con el propósito de mejorar la precisión en el diagnóstico de la enfermedad.

## **3.2. Objetivos Específicos**

- Realizar preprocesamiento y procesamiento de imágenes para asegurar la calidad y consistencia de la información, así como para eliminar posibles ruidos o errores.
- Desarrollar 10 modelos de aprendizaje automático para realizar las tareas de segmentación y clasificación de imágenes ultrasónicas.
- Implementar los modelos entrenados en una mini-computadora que

- permita realizar análisis de imágenes de US en tiempo real.
- Evaluar mediante métricas específicas, el preprocesamiento de imágenes, la segmentación de imágenes y, la extracción de características y clasificación.
- Entrenar y validar el mejor modelo utilizando conjuntos de datos clínicos adecuados, evaluando su rendimiento mediante métricas específicas para la predicción de cáncer, como sensibilidad, especificidad, precisión y valor predictivo.

## 4. Materiales y métodos

### 4.1. Metodología

En este proyecto se realizará el desarrollo de 10 modelos de *Machine Learning* y/o *Deep Learning* con la finalidad de entrenarlos para dos tareas fundamentales en el diagnóstico de imágenes médicas: la segmentación y la clasificación. Los modelos entrenados serán implementados en una mini-computadora capaz de soportar tareas de Inteligencia Artificial en tiempo real para poder recibir un nuevo conjunto de imágenes de ultrasonido de cáncer de mama mediante una interfaz de usuario para realizar el análisis y diagnóstico de imágenes utilizando el mejor modelo.

#### **NVIDIA Jetson Nano**

La mini-computadora elegida para este trabajo es NVIDIA Jetson Nano, la cual se caracteriza por presentar un consumo de energía eficiente a pesar de destacar por su velocidad de cómputo con solo 5 a 10 vatios, por su precisión y por ser un modelo compacto de 70 x 45 mm [24][25]. Esta placa requiere de una alimentación externa de 5V y cuenta con 4 GB de memoria principal, permitiendo además la inclusión de una tarjeta secundaria como una microSD [26].

#### **Dataset**

La base de datos consta de 780 imágenes en formato PNG de ultrasonido mamario con un tamaño promedio de imagen de 500 x 500 píxeles. Todas las imágenes han sido clasificadas exclusivamente en las categorías normal, benigno o maligno.

La data fue adquirida en 600 pacientes mujeres de entre 25 años a 75 años en el año 2018 en el Hospital Baheya en el Cairo, Egipto [27].

Las imágenes del set de datos han sido adquiridas con los instrumentos: sistema de ultrasonido LOGIQ E9 y LOGIQ E9 Agile, los cuales se caracterizan por brindar una resolución de 1280x1024 [27].

El proceso de desarrollo del proyecto consta de 4 etapas:

- **Etapas 1:** Preprocesamiento de las imágenes  
El objetivo de la implementación del preprocesamiento de imágenes en este proyecto tiene como propósito reducir los artefactos generados durante la

adquisición de la imagen, mejorar la región de interés, eliminar data errónea y estandarizar las imágenes que componen el dataset [28].

El *dataset* de imágenes de ultrasonido mamario con el que se cuenta para este trabajo, tras la inspección visual de la data, se encontrará sujeto a tres técnicas de preprocesamiento.

La primera técnica de preprocesamiento es la mejora de contraste de las imágenes del dataset con el objetivo de delimitar y diferenciar mejor ciertas regiones de interés, especialmente, cuando los valores de contraste son muy similares a los del fondo de la imagen [29]. Este incremento de contraste podrá realizarse mediante el método tradicional por *Contrast Limited Adaptive Histogram Equalization* [30][29] o usando transformaciones logarítmicas y exponenciales sobre la imagen [31].

La normalización de la intensidad es la segunda técnica de preprocesamiento que se aplicará para disminuir las diferencias en brillo y de variabilidad de todas las imágenes del dataset [32][33]. Esa normalización de intensidad se logrará con un escalamiento de la intensidad en la escala de 0 a 255 teniendo en cuenta los mínimos y máximos valores de intensidad de las imágenes.

Finalmente, la última técnica consistirá en la eliminación de ruido debido a que las imágenes de ultrasonido se encuentran típicamente afectadas por el “*speckle noise*” el cual introduce fluctuaciones en la intensidad de la imagen impactando en la calidad de la imagen y afectando la interpretación de las redes neuronales [34]. La sustracción del ruido puede darse a través de distintos métodos como el filtro mediano, filtro gaussiano y filtro medio [35].

- **Etapla 2:** Selección de características

El aprendizaje profundo, o deep learning, es capaz de entrenarse gracias a su capacidad para aprender automáticamente a partir de datos. En este caso, se recopilan y etiquetan las imágenes, para posteriormente dividir las en conjuntos de entrenamiento, validación y prueba.

Con los datos listos, seleccionamos una arquitectura de red neuronal profunda apropiada para la tarea en cuestión e inicializamos los pesos de la red de manera aleatoria. De esta manera, cada imagen en el conjunto de entrenamiento es introducida en la red neuronal, pasando a través de múltiples capas. Durante este proceso, la red aprende a identificar patrones y características en las imágenes a medida que se propagan a través de dichas capas [36].

Asimismo, tras la propagación se calcula la pérdida o error comparando la salida de la red con las etiquetas verdaderas de las imágenes y, utilizando un algoritmo de retropropagación, la red ajusta sus pesos para minimizar esta pérdida [37]. Este proceso de ajuste de pesos se realiza iterativamente durante múltiples iteraciones sobre el conjunto de entrenamiento.



Luego de cada iteración, se evalúa el desempeño del modelo en un conjunto de datos de validación para evitar el sobreajuste y ajustar los hiperparámetros si es necesario [37]. Una vez que el modelo ha alcanzado un rendimiento satisfactorio en el conjunto de validación, puede ser utilizado para hacer predicciones en datos nuevos sin etiquetar, lo que permite una amplia gama de aplicaciones prácticas, desde reconocimiento de imágenes hasta diagnóstico médico y mucho más.

Para entrenar el modelo, se tomarán en cuenta diferentes arquitecturas de redes neuronales profundas (deep learning) utilizadas principalmente en tareas de visión por computadora, como la clasificación de imágenes, la segmentación semántica, la detección de objetos, entre otras:

- Resnet
- U-Net
- DenseNet
- DeepLab
- EfficientNet
- SegNet
- FCN (Fully Convolutional Network)
- Mask R-CNN

No todas estas arquitecturas están diseñadas específicamente para la clasificación de imágenes. Algunas, como ResNet, DenseNet, EfficientNet y algunas variantes de SegNet, tienen el potencial de ser utilizadas para la clasificación de imágenes, ya que son redes neuronales convolucionales que pueden aprender a asignar etiquetas a imágenes [38]. Sin embargo, otras arquitecturas, como U-Net, DeepLab, FCN y Mask R-CNN, están más orientadas a tareas de segmentación semántica y detección de objetos, donde se requiere identificar y delimitar objetos en una imagen en lugar de simplemente asignar una etiqueta a la imagen en su totalidad [39] [40].

- **Etapas 3:** Evaluación de los modelos (5-10 modelos)

En el contexto de evaluación de modelos de deep learning para clasificación de imágenes, se utilizan varias métricas para medir la calidad y el rendimiento del modelo [41]:

- Precisión (Accuracy): La precisión es una medida que indica la proporción de imágenes clasificadas correctamente por el modelo respecto al total de imágenes evaluadas. En el contexto de clasificación de imágenes, es la cantidad de imágenes correctamente clasificadas (verdaderos positivos y verdaderos negativos) dividida por el número total de imágenes.
- Exhaustividad (Recall): La exhaustividad, también conocida como sensibilidad, es una medida que indica la proporción de imágenes positivas que fueron identificadas correctamente por el modelo. En el contexto de clasificación de imágenes, es la cantidad de imágenes

positivas correctamente clasificadas (verdaderos positivos) dividida por el número total de imágenes positivas en el conjunto de datos.

- **Precisión (Precision):** La precisión es una medida que indica la proporción de imágenes positivas clasificadas correctamente entre todas las imágenes clasificadas como positivas por el modelo. En el contexto de clasificación de imágenes, es la cantidad de imágenes positivas correctamente clasificadas (verdaderos positivos) dividida por el número total de imágenes clasificadas como positivas por el modelo (verdaderos positivos más falsos positivos).

Por otro lado, en el campo de segmentación de imágenes, se emplea el Puntaje de Dice, la Distancia de Hausdorff Promedio y la Similitud Volumétrica para cuantificar la precisión y efectividad de los algoritmos.

- **Puntaje de Dice:** El puntaje de Dice es una medida de similitud utilizada en la segmentación de imágenes para evaluar cuánto se superpone una máscara de segmentación predicha con la máscara de segmentación real [42]. Va de 0 a 1, donde 0 significa ninguna superposición y 1 indica una superposición perfecta. Es crucial en la imagen médica para evaluar la precisión de los algoritmos de segmentación. Se calcula como el doble del área de superposición entre las máscaras, dividido por la suma de sus áreas totales. Es una métrica robusta que normaliza la superposición en función del tamaño de las máscaras, lo que la hace útil para evaluar modelos de inteligencia artificial en la segmentación de imágenes.

$$Dice\ score = \frac{2 * (Area\ of\ overlap)}{(Total\ area)} \quad (Equation\ 1)$$

- **Distancia de Hausdorff Promedio (AHD):** La distancia de Hausdorff promedio es una medida que evalúa la similitud entre dos conjuntos de puntos, como las regiones segmentadas en una imagen y la verdad fundamental. Se enfoca en cuánto se parecen las formas y posiciones de los contornos en ambas segmentaciones [43]. Se prefiere el uso de la distancia de Hausdorff promedio simétrica debido a su robustez frente a valores atípicos. Un valor cercano a cero indica una buena coincidencia entre los contornos, mientras que un valor más alto sugiere menos precisión en la segmentación.

$$d(A, B) = \frac{1}{N} \sum_{a \in A} \min_{b \in B} ||a - b|| \quad (Equation\ 2.1)$$

$$AHD(A, B) = \max(d(A, B), d(B, A)) \quad (Equation\ 2.2)$$

- **Etapas 4:** Desarrollo de una IU

Finalmente, como parte de conseguir portabilidad del mejor modelo entrenado, se implementará dicho modelo en una placa de sistema embebido NVIDIA Jetson Nano con el fin de evaluar su potencial y sostenibilidad para el desarrollo de aplicaciones en futuros proyectos [44].

Esta etapa contará con dos subetapas específicas: 1) la adquisición de la imagen de ultrasonido de cáncer de mama a partir de una nueva imagen guardada en una memoria USB, dado quede de lo contrario se necesitaría acceder directamente a un ecógrafo; 2) el procesamiento que se realizará localmente y en tiempo real en el sistema embebido [45].

## 4.2. Consideraciones éticas

El presente proyecto no involucra humanos ni animales.

La base de datos utilizada para este proyecto es de dominio público y se encuentra publicada por Walid Al-Dhabyani, Mohammed Gomaa, Hussien Khaled y Aly Fahmy en Dataset of breast ultrasound images [27] y disponible en [46].

## 5. Cronograma

Actividades		Línea temporal				
		1 <sup>er</sup> mes	2 <sup>o</sup> mes	3 <sup>er</sup> mes	4 <sup>o</sup> mes	5 <sup>o</sup> mes
<b>Metodología VDI 2221</b>	Identificación de requerimientos (exigencias y deseos)					
	Descripción de la propuesta de solución y boceto					
	Esquema de funciones					
	Matriz morfológica del concepto de solución y boceto final					
<b>Desarrollo del prototipo</b>	Desarrollo de software (10 modelos)					
	Inicio del desarrollo de la electrónica del prototipo					
	Implementación de la propuesta de software en Jetson Nano					
	Inicio del diseño de hardware					
	Inicio de la fabricación del hardware					
<b>Revisión</b>	Redacción y corrección de artículo					

## 6. Presupuesto

CATEGORÍA	DESCRIPCIÓN	TOTAL
Laptop	Equipo utilizado para realizar el procesamiento	S/. 1200.00
Jetson nano	Para desarrollo de un prototipo análisis de imágenes médicas en tiempo real mediante modelos de IA	S/.1000.00

## 7. Referencias

[1] Y. Xu et al., “Global trends and forecasts of breast cancer incidence and deaths,” Scientific Data, vol. 10, no. 1, May 2023. doi:10.1038/s41597-023-02253-5

[2] Y. Feng et al., “Breast cancer development and progression: Risk factors, cancer stem cells, signaling pathways, genomics, and Molecular Pathogenesis,” Genes & diseases, <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6147049/> (accessed Apr. 9, 2024).

[3] “Breast cancer,” World Health Organization, <https://www.who.int/news-room/fact-sheets/detail/breast-cancer> (accessed Apr. 9, 2024).

[4] “What is breast cancer?,” Centers for Disease Control and Prevention, [https://www.cdc.gov/cancer/breast/basic\\_info/what-is-breast-cancer.htm](https://www.cdc.gov/cancer/breast/basic_info/what-is-breast-cancer.htm) (accessed Apr. 9, 2024).

[5] “Breast cancer staging,” American College of Surgeons, <https://www.facs.org/for-patients/home-skills-for-patients/breast-cancer-surgery/breast-cancer-types/breast-cancer-staging/#:~:text=There%20are%20five%20stages%20of,when%20you%20are%20first%20diagnosed> (accessed Apr. 9, 2024).

[6] Bcrf, “Metastatic breast cancer: Symptoms, treatment, research: BCRF,” Breast Cancer Research Foundation, <https://www.bcrf.org/blog/metastatic-breast-cancer-symptoms-treatment> (accessed Apr. 9, 2024).

[7] “Cáncer de mama,” Cancer.net, Jun. 17, 2014. <https://www.cancer.net/es/tipos-de-c%C3%A1ncer/c%C3%A1ncer-de-mama> (accessed Apr. 09, 2024).

[8] Z. D. Morante et al., “Diagnosis and treatment of HER2 + breast cancer: Clinical Practice Guide of the Peruvian Society of Cancerology,” SciELO, vol. 81, no. 4, pp. 458–465, Dec. 2020. [Online]. Available: <https://dx.doi.org/10.15381/anales.v81i4.18839>

[9] “Vista de El cáncer de mama en el Perú y el mundo,” Intercienciamedica.com, 2024. <https://intercienciamedica.com/intercienciamedica/article/view/89/87> (accessed Apr. 09,

2024).

[10] World, "El diagnóstico temprano del cáncer salva vidas y reduce los costos de tratamiento," Who.int, Feb. 03, 2017. <https://www.who.int/es/news/item/03-02-2017-early-cancer-diagnosis-saves-lives-cuts-treatment-costs> (accessed Apr. 09, 2024).

[11] A. RSNA, "Ultrasonido de Senos," Radiologyinfo.org, 2022. <https://www.radiologyinfo.org/es/info/breastus> (accessed Apr. 09, 2024).

[12] K. Malherbe and Dawood Tafti, "Breast Ultrasound," Nih.gov, Jan. 10, 2024. <https://www.ncbi.nlm.nih.gov/books/NBK557837/> (accessed Apr. 10, 2024).

[13] "The role of breast ultrasound in monitoring breast health - Sonoworld London," Sonoworld London, Jan. 27, 2023. <https://sonoworld.co.uk/blog/the-role-of-breast-ultrasound-in-monitoring-breast-health> (accessed Apr. 10, 2024).

[14] N. La and N. Román, "Técnicas de Segmentación en Procesamiento Digital de Imágenes," Revista de investigación de Sistemas e Informática, vol. 6, no. 2, pp. 9–16, 2024, Accessed: Apr. 10, 2024. [Online]. Available: <https://revistasinvestigacion.unmsm.edu.pe/index.php/sistem/article/view/3299>

[15] DeepLobe, "Image Segmentation: What Are the Most Interesting Applications?," DeepLobe, Feb. 28, 2023. <https://deeplobe.ai/image-segmentation-the-most-interesting-applications/> (accessed Apr. 10, 2024).

[16] G. Cover, William Garcia Herrera, M. P. Bento, S. Appenzeller, and L. Rittner, "Computational methods for corpus callosum segmentation on MRI: A systematic literature review," Computer methods and programs in biomedicine (Print), vol. 154, pp. 25–35, Feb. 2018, doi: <https://doi.org/10.1016/j.cmpb.2017.10.025>.

[17] M. angella, "Mastering the Art of Image Segmentation: A Comprehensive Guide to Image Segmentation Techniques," Medium, Aug. 2023. <https://medium.com/@1marcusangella/mastering-the-art-of-image-segmentation-a-comprehensive-guide-to-image-segmentation-techniques-545a75010a35> (accessed Apr. 10, 2024).

[18] H. Seo et al., "Machine learning techniques for biomedical image segmentation: An overview of technical aspects and introduction to state-of-art applications," Medical physics (Lancaster), vol. 47, no. 5, May 2020, doi: <https://doi.org/10.1002/mp.13649>.

[19] Neven Pičuljan and Ž. Car, "Machine Learning-Based Label Quality Assurance for Object Detection Projects in Requirements Engineering," Applied sciences (Basel), vol. 13, no. 10, pp. 6234–6234, May 2023, doi: <https://doi.org/10.3390/app13106234>.

[20] "(PDF) Robust image processing: definition, algorithms and evaluation," ResearchGate, 2018. [https://www.researchgate.net/publication/325060014\\_Robust\\_image\\_processing\\_definition\\_algorithms\\_and\\_evaluation](https://www.researchgate.net/publication/325060014_Robust_image_processing_definition_algorithms_and_evaluation) (accessed Apr. 10, 2024).

[21] Mohammad Mustafa Taye, "Understanding of Machine Learning with Deep Learning: Architectures, Workflow, Applications and Future Directions," Computers (Basel), vol. 12, no.

5, pp. 91–91, Apr. 2023, doi: <https://doi.org/10.3390/computers12050091>.

[22] Nivelics, “Deep Learning: Descubre la Inteligencia Artificial [Nivelics,” Nivelics, Jun. 22, 2023.

<https://www.nivelics.com/blog/beneficios-del-aprendizaje-profundo-descubriendo-un-nuevo-horizonte-de-la-inteligencia-artificial> (accessed Apr. 10, 2024).

[23] Mahmoud Elmahdy and R. Sebro, “Radiomics analysis in medical imaging research,” *Journal of medical radiation sciences*, vol. 70, no. 1, pp. 3–7, Feb. 2023, doi: <https://doi.org/10.1002/jmrs.662>.

[24] “Jetson Nano de Nvidia,” NVIDIA, <https://www.nvidia.com/es-la/autonomous-machines/embedded-systems/jetson-nano/product-development/> (accessed Apr. 14, 2024).

[25] [1] H. Ulutas, M. E. Sahin, and M. O. Karakus, “Application of a novel deep learning technique using CT images for covid-19 diagnosis on embedded systems,” *Alexandria Engineering Journal*, vol. 74, pp. 345–358, Jul. 2023. doi:10.1016/j.aej.2023.05.036

[26] [1] M. Lapeгна, W. Balzano, N. Meyer, and D. Romano, “Clustering algorithms on low-power and high-performance devices for Edge Computing Environments,” *Sensors*, vol. 21, no. 16, p. 5395, Aug. 2021. doi:10.3390/s21165395

[27] W. Al-Dhabyani, M. Gomaa, H. Khaled, and A. Fahmy, “Dataset of breast ultrasound images,” *Data in Brief*, vol. 28, p. 104863, Feb. 2020. doi:10.1016/j.dib.2019.104863

[28] K. Kalyan, B. Jakhia, R. D. Lele, M. Joshi, and A. Chowdhary, “Artificial neural network application in the diagnosis of disease conditions with liver ultrasound images,” *Advances in Bioinformatics*, vol. 2014, pp. 1–14, Sep. 2014. doi:10.1155/2014/708279

[29] S. Tripathy and T. Swarnkar, “Unified preprocessing and enhancement technique for mammogram images,” *Procedia Computer Science*, vol. 167, pp. 285–292, 2020. doi:10.1016/j.procs.2020.03.223

[30] Y. Wang and Y. Yao, “Breast lesion detection using an anchor-free network from ultrasound images with segmentation-based enhancement,” *Scientific Reports*, vol. 12, no. 1, Aug. 2022. doi:10.1038/s41598-022-18747-y

[31] X. Li, Y. Wang, Y. Zhao, and Y. Wei, “Fast speckle noise suppression algorithm in breast ultrasound image using three-dimensional deep learning,” *Frontiers in Physiology*, vol. 13, Apr. 2022. doi:10.3389/fphys.2022.880966

[32] H. Shu *et al.*, “A deep learning approach to re-create raw full-field digital mammograms for breast density and texture analysis,” *Radiology: Artificial Intelligence*, vol. 3, no. 4, Jul. 2021. doi:10.1148/ryai.2021200097

[33] Y.-W. Chang, Y.-R. Chen, C.-C. Ko, W.-Y. Lin, and K.-P. Lin, “A novel computer-aided-diagnosis system for breast ultrasound images based on BI-RADS categories,” *Applied Sciences*, vol. 10, no. 5, p. 1830, Mar. 2020. doi:10.3390/app10051830

[34] M. Alzubaidi *et al.*, “A composite image processing technique to enhance segmentation of ultrasound images,” *Proceedings of the 2022 5th International Conference on Digital Medicine and Image Processing*, Nov. 2022. doi:10.1145/3576938.3576939

- [35] S. Cai, Y. Zhu, J. Zhang and T. Liu, "A Study on the Combination of Image Preprocessing Method Based on Texture Feature and Segmentation Algorithm for Breast Ultrasound Images," 2022 2nd International Conference on Consumer Electronics and Computer Engineering (ICCECE), Guangzhou, China, 2022, pp. 760-764, doi: 10.1109/ICCECE54139.2022.9712824.
- [36] E. Burns, "Aprendizaje profundo (deep learning)," ComputerWeekly.es, 2021. <https://www.computerweekly.com/es/definicion/Aprendizaje-profundo-deep-learning> (accessed Apr. 14, 2024).
- [37] "Guía completa sobre la propagación hacia atrás en redes neuronales profundas - Prompts para IA," Prompts para IA, Feb. 23, 2024. <https://prompt.uno/redes-neuronales-profundas/explicacion-de-la-propagacion-hacia-atras-en-redes-neuronales-profundas/> (accessed Apr. 14, 2024).
- [38] "ResNet: The Basics and 3 ResNet Extensions," Datagen, May 23, 2023. <https://datagen.tech/guides/computer-vision/resnet/#> (accessed Apr. 14, 2024).
- [39] A. Acharya, "Instance Segmentation in Computer Vision: A Comprehensive Guide," Encord.com, Nov. 26, 2023. <https://encord.com/blog/instance-segmentation-guide-computer-vision/> (accessed Apr. 14, 2024).
- [40] "Papers with Code - DeepLab Explained," Paperswithcode.com, 2020. <https://paperswithcode.com/method/deeplab> (accessed Apr. 14, 2024).
- [41] J. Ignacio, "La matriz de confusión y sus métricas – Inteligencia Artificial –," Juan Barrios, Jul. 26, 2019. <https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/> (accessed Apr. 14, 2024).
- [42] "Dice score - OECD.AI," Oecd.ai, 2024. <https://oecd.ai/en/catalogue/metrics/dice-score> (accessed Apr. 14, 2024).
- [43] Taha AA, Hanbury A. Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool. BMC Med Imaging. 2015;15(1):29. <https://doi.org/10.1186/s12880-015-0068-x>.
- [44] H. Ulutas, M. E. Sahin, and M. O. Karakus, "Application of a novel deep learning technique using CT images for covid-19 diagnosis on embedded systems," *Alexandria Engineering Journal*, vol. 74, pp. 345–358, Jul. 2023. doi:10.1016/j.aej.2023.05.036
- [45] H. M. Mohan, S. Anitha, R. Chai, and S. H. Ling, "Edge Artificial Intelligence: Real-time noninvasive technique for vital signs of myocardial infarction recognition using Jetson Nano," *Advances in Human-Computer Interaction*, vol. 2021, pp. 1–19, Aug. 2021. doi:10.1155/2021/6483003
- [46] A. Shah, "Breast Ultrasound Images Dataset," Kaggle, <https://www.kaggle.com/datasets/aryashah2k/breast-ultrasound-images-dataset> (accessed Apr. 14, 2024).

Apr. 9, 2024).