

Algoritmo para la Optimización de Análisis en Ecografías Mamarias para la Detección Temprana del Cáncer de Mama en Entornos con Recursos Limitados

by ALDAVE JAVIER ALESSANDRA MERCEDES

Submission date: 14-Jun-2024 03:09PM (UTC-0500)

Submission ID: 2401334662

File name: Copia_Nueva_de_Protocolo_Actualizado_-_Equipo_6.pdf (187.03K)

Word count: 4615

Character count: 28763

ÍNDICE

4	1. Introducción.....	3
	2. Marco Teórico.....	4
	2.1. Ultrasonido mamario.....	4
	2.2. Segmentación de imágenes.....	5
	2.3. Key Frame Extraction.....	5
	2.4. Aprendizaje profundo.....	5
3	3. Objetivos del proyecto.....	6
	3.1. Objetivo General.....	6
	3.2. Objetivos Específicos.....	6
4	4. Materiales y métodos.....	6
	4.1. Metodología.....	7
	4.2. Consideraciones éticas.....	10
	5. Cronograma.....	11
	6. Presupuesto.....	11
	7. Referencias.....	12

1. Introducción

Por muchos años y hasta la actualidad, el cáncer de mamario (CM) constituye uno de los más grandes desafíos de administración sanitaria a alrededor del mundo [1][2], en donde casi el 100% de los casos de CM se manifiestan en mujeres y dentro de un intervalo de 0.5% a 1%, en hombres [3].

El cáncer de mama se caracteriza por ser una enfermedad en la cual las células que pertenecen al tejido mamario se encuentran en un proceso de crecimiento sin control [4]. Cuando la identificación y valoración del estado de esta enfermedad se efectúa de manera temprana, las probabilidades de éxito que se puede conseguir con el tratamiento son altas; no obstante, si la detección es tardía, el porcentaje de proliferación de células tumorales resulta elevado, lo cual sitúa la condición de la persona que adolece la enfermedad en el último estadio del cáncer de seno (estadio IV) [5] en el cual, el cáncer inicialmente concentrado en las mamas se disemina hacia otras áreas del cuerpo conduciendo a un cáncer metastásico que, pese a que puede ser tratado, permanece incurable [6].

A nivel global, las cifras son alarmantes: en el año 2020 se diagnosticaron aproximadamente 2.26 millones de nuevos casos de CM, lo que lo posiciona como la causa principal número cinco de muerte en mujeres, con 685,000 fallecimientos registrados [7]. En el 2022, el CM ha sido la variedad de cáncer más extendida entre la población femenina en 157 países de 185, y en el mismo año, esta enfermedad produjo 670 000 muertes a nivel global [3]. Sin embargo, persisten desigualdades significativas en la distribución de la enfermedad. En naciones con un muy alto Índice de Desarrollo Humano, 1 de cada 12 mujeres son diagnosticadas y 1 en 71 mujeres mueren por cáncer de mama. En contraste, en países con bajo IDH, solamente a 1 de cada 27 mujeres se le detecta con CM y se estima que 1 de cada 48 mujeres morirán bajo esta causa [3].

En el contexto peruano, la situación no es menos preocupante. El CM es el tipo más común de cáncer entre las mujeres peruanas [8]. Además, con una incidencia en constante aumento, anualmente, se reportan unos 28 casos nuevos por cada 100,000 residentes, reflejando una tendencia preocupante en las últimas dos décadas [9].

En este escenario, la detección temprana emerge como un factor crucial para elevar las tasas de supervivencia. El diagnóstico temprano de CM no solo aumenta las posibilidades de cura al detectar la enfermedad en etapas más tempranas, cuando el tumor es más tratable, sino que también abre la puerta a opciones de tratamiento menos invasivas, preservando así el estándar de vida de las pacientes [10]. Además, detectar la enfermedad a tiempo se refleja en una baja en las tasas de mortalidad asociada a la enfermedad, salvando vidas y mejorando el pronóstico general.

Asimismo, cabe resaltar la desigualdad en los criterios de tamizaje en los sistemas de salud, así como a la falta de una cultura preventiva adecuada y a la concentración de mamógrafos en la ciudad de Lima. Según datos recopilados hasta el 2022 por La República, de la Dirección de Prevención y Control de Cáncer del Ministerio de Salud (Minsa), solo 31 de los 49 mamógrafos disponibles en los hospitales del país están operativos. Este panorama es preocupante considerando que, según el Instituto

Nacional de Estadística e Informática (INEI), existe en promedio un mamógrafo por cada 1 millón de residentes en Perú, que actualmente supera los 33 millones [11].

Además, estos mamógrafos en funcionamiento no están distribuidos equitativamente en todas las regiones del país, lo que significa que solo algunas tienen acceso a estos equipos cruciales para el diagnóstico temprano del CM. La falta de diagnóstico se ve agravada por la escasez de profesionales capacitados para operar estas máquinas esenciales en el diagnóstico de la enfermedad.

A diario se diagnostican 19 nuevos casos de CM en Perú, afectando aproximadamente a 6,860 personas al año. Es evidente que se requiere no solo más equipos, sino también una inversión significativa en la capacitación de personal médico para utilizar eficazmente estos recursos [12].

2. Marco Teórico

2.1. Ultrasonido mamario

El ultrasonido mamario o ultrasonido de seno, una técnica no invasiva y altamente versátil en el ámbito médico, desempeña un papel integral en el diagnóstico y seguimiento de patologías mamarias. Su funcionamiento se basa en el principio piezoeléctrico, donde un transductor emite ondas sonoras de alta frecuencia que atraviesan los tejidos mamarios y se reflejan de manera diferencial, dependiendo de la composición y características de dichos tejidos. Estas señales reflejadas son detectadas por el transductor y luego procesadas por un sistema encargado de generar imágenes detalladas en escala de grises, ofreciendo una representación visual del interior de la mama [12].

La utilidad del ultrasonido mamario abarca diversas áreas. En primer lugar, es ampliamente empleado para la detección y caracterización de nódulos mamarios. Su capacidad para identificar incluso las lesiones más pequeñas y sutiles, así como su habilidad para diferenciar entre masas sólidas y quísticas, lo convierten en una herramienta invaluable en el diagnóstico precoz de enfermedades mamarias [13]. Además, el ultrasonido mamario se utiliza en la evaluación de anomalías detectadas en mamografías o resonancias magnéticas mamarias, proporcionando información adicional que puede ser crucial para el tratamiento y manejo de la enfermedad.

Otro aspecto crucial es su utilidad como guía en procedimientos invasivos, como biopsias. El ultrasonido mamario permite una visualización en tiempo real de la ubicación exacta del tejido anormal, lo que facilita la obtención de muestras precisas para análisis patológicos [14]. Además, su papel en la detección complementaria del cáncer de seno es invaluable, especialmente en casos donde la mamografía puede resultar limitada, como en senos densos [12].

2.2. Segmentación de imágenes

La segmentación de imágenes es un proceso fundamental en el análisis de imágenes digitales, que implica la división de una imagen en sus elementos constituyentes [15]. En el contexto del cáncer de mama, se utiliza para identificar los límites de un tumor en una imagen de ultrasonido.

Los objetivos de la segmentación de imágenes son extraer información relevante, como separar los objetos de interés del fondo y de otros objetos, cuantificar características como tamaño, forma y textura, y facilitar el análisis posterior para otras tareas de procesamiento de imágenes [16].

Existen varios métodos de segmentación de imágenes, incluyendo la segmentación basada en umbrales, que establece un umbral de intensidad de píxeles para clasificarlos como parte del objeto de interés del fondo [17]; la segmentación mediante detección de bordes, que identifica los contornos de los objetos en la imagen para delimitar el área de interés del objeto; la segmentación basada en regiones, que agrupa píxeles con características similares en regiones que representan los objetos de interés [18]; y la segmentación basada en aprendizaje automático, que utiliza algoritmos de aprendizaje automático para aprender a segmentar objetos en imágenes a partir de ejemplos [19].

2.3. Key Frame Extraction

La extracción de fotogramas clave (*Key Frame Extraction*) es el proceso de seleccionar fotogramas específicos de un video que puedan resumir de manera efectiva su contenido. Este método permite emplear únicamente una parte de los cuadros totales, lo cual disminuye la cantidad de datos que se deben procesar, optimizando así el análisis de video.

Definir lo que constituye un buen fotograma clave es a menudo subjetivo y no existe un único factor para evaluar su calidad. Con frecuencia se menciona que las técnicas de extracción de fotogramas clave seleccionan los mejores fotogramas de un video, pero la definición de un buen fotograma clave está relacionada con el caso de uso del método de extracción. Una técnica adecuada debería extraer los fotogramas más representativos y que transmitan la información más importante de un video [20].

2.4. Aprendizaje profundo

El aprendizaje profundo se refiere a una rama del aprendizaje automático que utiliza redes neuronales artificiales con múltiples capas para adquirir características sofisticadas a partir de los datos, simulando la manera de aprendizaje de un cerebro humano [21]. Estos modelos han exhibido excelentes

resultados en varias áreas de clasificación y reconocimiento visual, como en la creación de sistemas para reconocimiento facial, vehículos autónomos y tecnologías de vigilancia inteligente. [21].

Entre las estructuras más frecuentes se encuentran las redes neuronales convolucionales (CNNs), ampliamente reconocidas por su eficacia en el análisis de imágenes, y las redes neuronales recurrentes (RNNs), especialmente útiles en el manejo y procesamiento de secuencias de datos; y las redes neuronales profundas convolucionales recurrentes (CNN-RNNs), que combinan ambas. Los beneficios del aprendizaje profundo incluyen mayor capacidad de aprendizaje, mejor rendimiento y mayor flexibilidad en la adaptación a diversas tareas y aplicaciones [8].

15

3. Objetivos del proyecto

3.1. Objetivo General

Desarrollar un algoritmo complementado con una interfaz gráfica que permita seleccionar los frames significativos de un video de ultrasonido (US) mamario para su posterior análisis por un profesional, con el propósito de aumentar la disponibilidad de diagnósticos de cáncer, facilitando el proceso de revisión y evaluación de los videos de ultrasonido mamario por parte de los especialistas.

3.2. Objetivos Específicos

- Realizar preprocesamiento y procesamiento de imágenes para asegurar la calidad y consistencia de la información, así como para eliminar posibles ruidos o errores.
- Desarrollar un modelo de segmentación y clasificación U-Net- CNN de imágenes ultrasónicas.
- Evaluar mediante métricas específicas, el preprocesamiento de imágenes, la segmentación de imágenes y, la extracción de características y clasificación.
- Entrenar y validar el mejor modelo utilizando conjuntos de datos clínicos adecuados, evaluando su rendimiento mediante métricas específicas para la predicción de cáncer, como sensibilidad, especificidad, precisión y valor predictivo.
- Implementar los modelos entrenados en una mini-computadora que permita realizar análisis de imágenes de US en tiempo real.

21

4. Materiales y métodos

4.1. Metodología

En este proyecto se realizará el desarrollo de 1 modelo fusionado de *Deep Learning* con la finalidad de entrenarlos para dos tareas fundamentales en el diagnóstico de imágenes médicas: la segmentación y la clasificación. Los modelos entrenados serán implementados en una mini-computadora capaz de soportar tareas de Inteligencia Artificial en tiempo real para poder recibir un nuevo conjunto de imágenes de ultrasonido de cáncer de mama mediante una interfaz de usuario para realizar el análisis y diagnóstico de imágenes utilizando el mejor modelo.

NVIDIA Jetson Nano

La mini-computadora elegida para este trabajo es NVIDIA Jetson Nano, la cual se caracteriza por presentar un consumo de energía eficiente a pesar de destacar por su velocidad de cómputo con solo 5 a 10 vatios, por su precisión y por ser un modelo compacto de 70 x 45 mm [22][23]. Esta placa requiere de una alimentación externa de 5V y cuenta con 4 GB de memoria principal, permitiendo además la inclusión de una tarjeta secundaria como una microSD [24].

Dataset

Este proyecto contará con dos conjuntos de datos que han sido preseleccionados para el proyecto de investigación, un conjunto principal para la tarea de clasificación y un conjunto auxiliar para facilitar la tarea de segmentación y predicción de máscaras.

La base de datos principal contiene 188 videos de ecografías mamarias adquiridos con los ecógrafos LOGIQ-E9 y PHILIPS TIS L9-3, de los cuales 113 son de lesiones malignas y 75, de lesiones benignas. Los videos están etiquetados con rectángulos que delimitan las lesiones mamarias y fueron clasificados por dos patólogos con ocho años de experiencia [25].

La base de datos auxiliar presenta 780 imágenes de extensión PNG de ultrasonido mamario, las dimensiones promedio de imagen son 500 x 500 píxeles. Todas las imágenes han sido clasificadas excluyentemente en las categorías normal, benigno o maligno.

La data fue adquirida en 600 pacientes mujeres de entre 25 años a 75 años en el año 2018 en el Hospital Baheya en el Cairo, Egipto [26].

Las imágenes del set de datos han sido adquiridas con los instrumentos: sistema de ultrasonido LOGIQ E9 y LOGIQ E9 Agile, los cuales se caracterizan por brindar una resolución de 1280x1024 [26].

El proceso de desarrollo del proyecto consta de 5 etapas:

- **Etapas 1:** Preprocesamiento de las imágenes
El objetivo de la implementación del preprocesamiento de imágenes en este proyecto tiene como propósito generalizar mejor el modelo U-Net-CNN mediante *data augmentation* y estandarizar las imágenes que componen el dataset [27].
Los *datasets* de imágenes de ultrasonido mamario con los que se cuentan para este trabajo, tras la inspección visual de la data, se encontrarán sujetos a

distintas transformaciones que no afecten las características fundamentales de las imágenes y videos originales como brillo, intensidad y contraste.

En principio, se aplicarán transformaciones de perspectiva como Perspective, Vertical Flip, Horizontal Flip; además de un redimensionamiento estándar de las imágenes según los requerimientos de entrada del modelo. ²Estas transformaciones permitirán aumentar la variedad de datos disponibles para el entrenamiento y validación del modelo en un dataset que cuenta con solo 188 videos.

- **Etapas 2: Segmentación y Predicción de máscaras**

El aprendizaje profundo, es capaz de entrenarse gracias a su habilidad para adquirir conocimiento de manera automática a partir de datos. En este caso, se recopilan y etiquetan las imágenes, para posteriormente dividirlos en conjuntos de entrenamiento, validación y prueba.

Con los datos listos, seleccionamos una arquitectura de red neuronal profunda apropiada para la tarea en cuestión e inicializamos los pesos de la red de manera aleatoria. De esta manera, cada imagen en el conjunto de entrenamiento es introducida en la red neuronal, pasando a través de múltiples capas. Durante este proceso, la red aprende a identificar patrones y características en las imágenes a medida que se propagan a través de dichas capas [28].

Arquitecturas conocidas como U-Net, DeepLab, FCN y Mask R-CNN, están más orientadas a tareas de segmentación semántica y detección de objetos, donde se requiere identificar y delimitar objetos en una imagen en lugar de simplemente asignar una etiqueta a la imagen en su totalidad [29] [30].

El modelo de U-Net seleccionado para este proyecto es un modelo de U-Net grande y preentrenado para la segmentación de tumores de mama a partir de imágenes de ultrasonido propuesto en la conferencia MICCAI 2023 [31]. Este modelo, presenta las siguientes características:

En su arquitectura de contracción y expansión, el encoder presenta cuatro capas de convolución y agrupación máxima (max pooling), que buscan reducir progresivamente la dimensionalidad espacial mientras incrementan profundidad de características. El decoder utiliza capas de transposición de convolución (ConvTranspose2d) y concatenación de características (UpConcat), seguidas por convoluciones para restaurar la resolución espacial.

Con respecto a las capas convolucionales de este modelo, se utilizan dos capas de convolución 3x3, además de una normalización por lotes (BatchNorm), una función de activación ReLU.

La elección de hiperparámetros se hará teniendo en cuenta artículos de referencia como [32]

Luego de cada iteración, se evalúa el desempeño del modelo con un ² conjunto de datos de validación para evitar el sobreajuste y ajustar los hiperparámetros si es necesario [33]. Una vez que el modelo ha alcanzado un rendimiento satisfactorio en el conjunto de validación, podrá ser utilizado para hacer predicciones de máscaras sobre nuevos sin etiquetar como los frames característicos del dataset principal, lo cual permitirá tener un algoritmo CNN de clasificación de frames característicos más eficiente.

- **Etapla 3: Algoritmo de Clasificación**

Se procederá con el diseño y entrenamiento ¹³ de un modelo de red neuronal convolucional (CNN) dedicado a la clasificación de fotogramas significativos en videos de ultrasonido mamario. Inicialmente, se realizará la carga y preprocesamiento de las imágenes, incluyendo métodos de aumento de datos para incrementar la variedad del conjunto de entrenamiento. Cada imagen será etiquetada como significativa o no, según su relevancia para el diagnóstico ulterior.

² Posteriormente, el conjunto de datos se dividirá de manera aleatoria en conjuntos de entrenamiento y prueba para garantizar la evaluación robusta del modelo. La arquitectura de la CNN estará compuesta por múltiples capas de convolución y pooling, diseñadas para captar características espaciales clave [34] en los fotogramas.

Las capas de convolución utilizarán filtros de tamaño (3, 3) con configuraciones escalonadas de 32, 64 y 64 filtros respectivamente. Después de estas capas, se aplicarán capas de MaxPooling (2, 2) para ⁶ disminuir la dimensionalidad y conservar las características más significativas. La función de activación ReLU se utilizará para introducir no linealidades en el modelo, optimizando así su capacidad de aprendizaje [35].

Una vez procesadas las características espaciales mediante las capas convolucionales, se aplicará una capa de flattening para convertir la salida en un vector unidimensional. Este vector será posteriormente procesado por una capa densa de 64 unidades con activación ReLU, antes de llegar a la capa de salida que empleará una función sigmoide para la clasificación binaria de los fotogramas como significativos o no.

Para la compilación del modelo, se utilizará el optimizador Adam debido a su eficacia en la adaptación del *learning rate* durante el entrenamiento [36]. Asimismo, la función de pérdida binary *cross entropy* será empleada, dado que se trata de un problema de clasificación binaria [37].

Además, se implementarán técnicas como early stopping para detener el entrenamiento si no se observa mejora en la validación tras dos épocas consecutivas, y *model checkpointing* para guardar el modelo con los mejores resultados según la métrica de pérdida de validación. Estas estrategias asegurarán que el modelo final sea óptimo y eficiente para la clasificación de fotogramas en videos de ultrasonido mamario.

- **Etapa 4: Evaluación del modelo**

En el contexto de evaluación de modelos de deep learning para clasificación de imágenes, se utilizan varias métricas para medir la calidad y el rendimiento del modelo [38]:

- Precisión (Accuracy): La precisión es un indicador que muestra qué tan exacto es el modelo al clasificar al comparar la proporción de las imágenes adecuadamente clasificadas en relación al total evaluado. En la clasificación de imágenes, se define como la proporción de imágenes correctamente clasificadas (verdaderos positivos y verdaderos negativos) entre el número total de imágenes.
- Exhaustividad (Recall): La exhaustividad, también conocida como sensibilidad, es una medida que indica la proporción de imágenes positivas que fueron identificadas correctamente por el modelo. En el contexto de clasificación de imágenes, es la cantidad de imágenes positivas correctamente clasificadas (verdaderos positivos) dividida entre el total de imágenes positivas en el conjunto de datos.

- **Etapa 5: Desarrollo de una IU**

Finalmente, como parte de conseguir portabilidad del mejor modelo entrenado, se implementará dicho modelo en una placa de sistema embebido NVIDIA Jetson Nano con el fin de evaluar su potencial y sostenibilidad para el desarrollo de aplicaciones en futuros proyectos [39].

Esta etapa contará con dos subetapas específicas: 1) la adquisición de la imagen de ultrasonido de cáncer de mama a partir de una nueva imagen guardada en una memoria USB, dado que de lo contrario se necesitaría acceder directamente a un ecógrafo; 2) el procesamiento que se realizará localmente y en tiempo real en el sistema embebido [40].

4.2. Consideraciones éticas

El presente proyecto no involucra humanos ni animales.

Las bases de datos utilizadas para este proyecto son de dominio público⁹ y se encuentran publicadas, en el caso del conjunto de datos auxiliar por Walid Al-Dhabyani, Mohammed Gomaa, Hussien Khaled y Aly Fahmy en Dataset¹⁰ of breast ultrasound images [27] y disponible en [41]. El dataset principal por Zhi

Lin, Junhao Lin, Lei Zhu, Huazhu Fu, Jing Qin, Liansheng Wang se encuentra disponible en [25].

5. Cronograma

Actividades		Línea temporal				
		12 1 ^{er} mes	2 ^o mes	3 ^{er} mes	4 ^o mes	5 ^o mes
Metodología VDI 2221	Identificación de requerimientos (exigencias y deseos)					
	Descripción de la propuesta de solución y boceto					
	Esquema de funciones					
	Matriz morfológica del concepto de solución y boceto final					
Desarrollo del prototipo	Desarrollo de software					
	Inicio del desarrollo de la electrónica del prototipo					
	Implementación de la propuesta de software en Jetson Nano					
	Inicio del diseño de hardware					
	Inicio de la fabricación del hardware					
Revisión	Redacción y corrección de artículo					

6. Presupuesto

CATEGORÍA	DESCRIPCIÓN	TOTAL
Laptop	Equipo utilizado para realizar el procesamiento	S/. 1200.00
Jetson nano	Para desarrollo de un prototipo análisis de imágenes médicas en tiempo real mediante modelos de IA	S/.1000.00

7. Referencias

- [1] Y. Xu et al., "Global trends and forecasts of breast cancer incidence and deaths," *Scientific Data*, vol. 10, no. 1, May 2023. doi:10.1038/s41597-023-02253-5
- [2] Y. Feng et al., "Breast cancer development and progression: Risk factors, cancer stem cells, signaling pathways, genomics, and Molecular Pathogenesis," *Genes & diseases*, <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6147049/> (accessed Apr. 9, 2024).
- [3] "Breast cancer," World Health Organization, <https://www.who.int/news-room/fact-sheets/detail/breast-cancer> (accessed Apr. 9, 2024).
- [4] "What is breast cancer?," Centers for Disease Control and Prevention, https://www.cdc.gov/cancer/breast/basic_info/what-is-breast-cancer.htm (accessed Apr. 9, 2024).
- [5] "Breast cancer staging," American College of Surgeons, <https://www.facs.org/for-patients/home-skills-for-patients/breast-cancer-surgery/breast-cancer-types/breast-cancer-staging/#:~:text=There%20are%20five%20stages%20of,when%20you%20are%20first%20diagnosed> (accessed Apr. 9, 2024).
- [6] Bcrf, "Metastatic breast cancer: Symptoms, treatment, research: BCRF," Breast Cancer Research Foundation, <https://www.bcrf.org/blog/metastatic-breast-cancer-symptoms-treatment> (accessed Apr. 9, 2024).
- [7] "Cáncer de mama," Cancer.net, Jun. 17, 2014. <https://www.cancer.net/es/tipos-de-c%C3%A1ncer/c%C3%A1ncer-de-mama> (accessed Apr. 09, 2024).
- [8] Z. D. Morante et al., "Diagnosis and treatment of HER2 + breast cancer: Clinical Practice Guide of the Peruvian Society of Cancerology," *SciELO*, vol. 81, no. 4, pp. 458–465, Dec. 2020. [Online]. Available: <https://dx.doi.org/10.15381/anales.v81i4.18839>
- [9] "Vista de El cáncer de mama en el Perú y el mundo," *Intercienciamedica.com*, 2024. <https://intercienciamedica.com/intercienciamedica/article/view/89/87> (accessed Apr. 09, 2024).
- [10] World, "El diagnóstico temprano del cáncer salva vidas y reduce los costos de tratamiento," *Who.int*, Feb. 03, 2017. <https://www.who.int/es/news/item/03-02-2017-early-cancer-diagnosis-saves-lives-cuts-treatment-costs> (accessed Apr. 09, 2024).
- [11] A. Ortega, "En el Perú, el Minsa solo tiene un mamógrafo operativo por cada millón de habitantes," *Larepublica.pe*, Oct. 20, 2022. <https://larepublica.pe/sociedad/2022/10/19/cancer-de-mama-en-el-peru-el-minsa-solo-tiene-1-mamografo-operativo-por-cada-millon-de-habitantes-dia-internacional-de-lucha-contra-el-cancer-de-mama> (accessed May 08, 2024).
- [12] A. RSNA, "Ultrasonido de Senos," *Radiologyinfo.org*, 2022. <https://www.radiologyinfo.org/es/info/breastus> (accessed Apr. 09, 2024).

- [13] K. Malherbe and Dawood Tafti, "Breast Ultrasound," Nih.gov, Jan. 10, 2024. <https://www.ncbi.nlm.nih.gov/books/NBK557837/> (accessed Apr. 10, 2024).
- [14] "The role of breast ultrasound in monitoring breast health - Sonoworld London," Sonoworld London, Jan. 27, 2023. <https://sonoworld.co.uk/blog/the-role-of-breast-ultrasound-in-monitoring-breast-health> (accessed Apr. 10, 2024).
- [15] N. La and N. Román, "Técnicas de Segmentación en Procesamiento Digital de Imágenes," *Revista de investigación de Sistemas e Informática*, vol. 6, no. 2, pp. 9–16, 2024, Accessed: Apr. 10, 2024. [Online]. Available: <https://revistasinvestigacion.unmsm.edu.pe/index.php/sistem/article/view/3299>
- [16] DeepLobe, "Image Segmentation: What Are the Most Interesting Applications?," DeepLobe, Feb. 28, 2023. <https://deeplobe.ai/image-segmentation-the-most-interesting-applications/> (accessed Apr. 10, 2024).
- [17] G. Cover, William Garcia Herrera, M. P. Bento, S. Appenzeller, and L. Rittner, "Computational methods for corpus callosum segmentation on MRI: A systematic literature review," *Computer methods and programs in biomedicine (Print)*, vol. 154, pp. 25–35, Feb. 2018, doi: <https://doi.org/10.1016/j.cmpb.2017.10.025>.
- [18] M. angella, "Mastering the Art of Image Segmentation: A Comprehensive Guide to Image Segmentation Techniques," Medium, Aug. 2023. <https://medium.com/@1marcusangella/mastering-the-art-of-image-segmentation-a-comprehensive-guide-to-image-segmentation-techniques-545a75010a35> (accessed Apr. 10, 2024).
- [19] H. Seo et al., "Machine learning techniques for biomedical image segmentation: An overview of technical aspects and introduction to state-of-art applications," *Medical physics (Lancaster)*, vol. 47, no. 5, May 2020, doi: <https://doi.org/10.1002/mp.13649>.
- [20] G. Lindgren, "A Comparison Between Key Frame Extraction Methods for Clothing Recognition," *Examensarbete 30 hp, UPTec IT 23023*, Jun. 12, 2023.
- [21] Nivelics, "Deep Learning: Descubre la Inteligencia Artificial |Nivelics," Nivelics, Jun. 22, 2023. <https://www.nivelics.com/blog/beneficios-del-aprendizaje-profundo-descubriendo-un-nuevo-horizonte-de-la-inteligencia-artificial> (accessed Apr. 10, 2024).
- [22] "Jetson Nano de Nvidia," NVIDIA, <https://www.nvidia.com/es-la/autonomous-machines/embedded-systems/jetson-nano/product-development/> (accessed Apr. 14, 2024).
- [23] H. Ulutas, M. E. Sahin, and M. O. Karakus, "Application of a novel deep learning technique using CT images for covid-19 diagnosis on embedded systems," *Alexandria Engineering Journal*, vol. 74, pp. 345–358, Jul. 2023. doi:10.1016/j.aej.2023.05.036
- [24] M. Lapeгна, W. Balzano, N. Meyer, and D. Romano, "Clustering algorithms on low-power and high-performance devices for Edge Computing Environments," *Sensors*, vol. 21, no. 16, p. 5395, Aug. 2021. doi:10.3390/s21165395
- [25] Z. Lin, J. Lin, L. Zhu, H. Fu, J. Qin, and L. Wang, "A New Dataset and a Baseline Model

for Breast Lesion Detection in Ultrasound Videos,” Lecture notes in computer science, pp. 614–623, Jan. 2022, doi: https://doi.org/10.1007/978-3-031-16437-8_59.

[26] W. Al-Dhabyani, M. Gomaa, H. Khaled, and A. Fahmy, “Dataset of breast ultrasound images,” *Data in Brief*, vol. 28, p. 104863, Feb. 2020. doi:10.1016/j.dib.2019.104863

[27] K. Kalyan, B. Jakhia, R. D. Lele, M. Joshi, and A. Chowdhary, “Artificial neural network application in the diagnosis of disease conditions with liver ultrasound images,” *Advances in Bioinformatics*, vol. 2014, pp. 1–14, Sep. 2014. doi:10.1155/2014/708279

[28] E. Burns, “Aprendizaje profundo (deep learning),” *ComputerWeekly.es*, 2021. <https://www.computerweekly.com/es/definicion/Aprendizaje-profundo-deep-learning> (accessed Apr. 14, 2024).

[29] A. Acharya, “Instance Segmentation in Computer Vision: A Comprehensive Guide,” *Encord.com*, Nov. 26, 2023. <https://encord.com/blog/instance-segmentation-guide-computer-vision/> (accessed Apr. 14, 2024).

[30] “Papers with Code - DeepLab Explained,” *Paperswithcode.com*, 2020. <https://paperswithcode.com/method/deeplab> (accessed Apr. 14, 2024).

[31] M. Li, K. Sun, Y. Gu, K. Zhang, Y. Sun, Z. Li, and D. Shen, “Developing Large Pre-trained Model for Breast Tumor Segmentation from Ultrasound Images,” in **MICCAI 2023**, Jun. 2023. [Online]. Available: <https://conferences.miccai.org/2023/papers/191-Paper1896.html>. [Accessed: Jun. 9, 2024].

[32] V. Anand, S. Gupta, Deepika Koundal, and K. Singh, “Fusion of U-Net and CNN model for segmentation and classification of skin lesion from dermoscopy images,” *Expert Systems with Applications*, vol. 213, pp. 119230–119230, Mar. 2023, doi: <https://doi.org/10.1016/j.eswa.2022.119230>.

[33] “Guía completa sobre la propagación hacia atrás en redes neuronales profundas - Prompts para IA,” *Prompts para IA*, Feb. 23, 2024. <https://prompt.uno/redes-neuronales-profundas/explicacion-de-la-propagacion-hacia-atras-en-redes-neuronales-profundas/> (accessed Apr. 14, 2024).

[34] Daniel, “Convolutional Neural Network : definición y funcionamiento,” *Formación en ciencia de datos | DataScientest.com*, Dec. 16, 2021. [https://datascientest.com/es/convolutional-neural-network-es#:~:text=Capa%20de%20Pooling%20\(POOL\)%3A,preservar%20sus%20caracter%C3%ADsticas%20m%C3%A1s%20esenciales.](https://datascientest.com/es/convolutional-neural-network-es#:~:text=Capa%20de%20Pooling%20(POOL)%3A,preservar%20sus%20caracter%C3%ADsticas%20m%C3%A1s%20esenciales.) (accessed Jun. 12, 2024).

[35] U. Modelo, “Construcción De Un Modelo De Red Neuronal Para Relaciones No Lineales - FasterCapital,” *FasterCapital*, 2024. <https://fastercapital.com/es/tema/construcci%C3%B3n-de-un-modelo-de-red-neuronal-para-relaciones-no-lineales.html> (accessed Jun. 12, 2024).

[36] J. Schäfer, “Adaptive Moment Estimation: Adam verstehen und richtig einsetzen,” *Konfuzio*, Dec. 20, 2023. <https://konfuzio.com/es/estimacion-adaptativa-de-momentos/#:~:text=La%20Estimaci%C3%99>

B3n%20Adaptativa%20de%20Momentos%20(Adam)%20es%20un%20algoritmo%20de,aprendizaje%20adaptativa%20para%20cada%20par%C3%A1metro. (accessed Jun. 12, 2024).

[37] “7.4: Funciones de Pérdida,” Mathematics LibreTexts, Dec. 16, 2021. https://math.libretexts.org/Courses/Universidad_Complutense_de_Madrid/Las_matematicas_de_la_inteligencia_artificial/07%3A_Redes_Neuronales/7.04%3A_Funciones_de_Perdida (accessed Jun. 12, 2024).

[38] J. Ignacio, “La matriz de confusión y sus métricas – Inteligencia Artificial –,” Juan Barrios, Jul. 26, 2019. <https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/> (accessed Apr. 14, 2024).

[39] H. Ulutas, M. E. Sahin, and M. O. Karakus, “Application of a novel deep learning technique using CT images for covid-19 diagnosis on embedded systems,” *Alexandria Engineering Journal*, vol. 74, pp. 345–358, Jul. 2023. doi:10.1016/j.aej.2023.05.036

[40] H. M. Mohan, S. Anitha, R. Chai, and S. H. Ling, “Edge Artificial Intelligence: Real-time noninvasive technique for vital signs of myocardial infarction recognition using Jetson Nano,” *Advances in Human-Computer Interaction*, vol. 2021, pp. 1–19, Aug. 2021. doi:10.1155/2021/6483003

[41] A. Shah, “Breast Ultrasound Images Dataset,” Kaggle, <https://www.kaggle.com/datasets/aryashah2k/breast-ultrasound-images-dataset> (accessed Apr. 9, 2024).

Algoritmo para la Optimización de Análisis en Ecografías Mamarias para la Detección Temprana del Cáncer de Mama en Entornos con Recursos Limitados

ORIGINALITY REPORT

9%

SIMILARITY INDEX

7%

INTERNET SOURCES

3%

PUBLICATIONS

3%

STUDENT PAPERS

PRIMARY SOURCES

1

larepublica.pe

Internet Source

1%

2

Ana Maria Jimenez Pastor. "Aprendizaje profundo y biomarcadores de imagen en el estudio de enfermedades metabólicas y hepáticas a partir de resonancia magnética y tomografía computarizada", Universitat Politecnica de Valencia, 2023

Publication

1%

3

repository.ucc.edu.co

Internet Source

1%

4

Belinda Marta Lema Cachinell, Alejandro Nicolas Lema Cachinell. "AVANCES INVESTIGATIVOS UNIDAD ACADÉMICA COMERCIAL 2023", ACVENISPROH Académico, 2023

Publication

1%

5

Submitted to Universidad Politecnica Salesiana del Ecuador

1%

6	Submitted to Universidad Internacional de la Rioja Student Paper	<1 %
7	Submitted to Universidad Anahuac México Sur Student Paper	<1 %
8	Submitted to Universidad de Valladolid Student Paper	<1 %
9	Submitted to University of the Andes Student Paper	<1 %
10	dblp.uni-trier.de Internet Source	<1 %
11	cme.nci.nih.gov Internet Source	<1 %
12	es.scribd.com Internet Source	<1 %
13	repositorio.espe.edu.ec Internet Source	<1 %
14	rinacional.tecnm.mx Internet Source	<1 %
15	www.disaster.info.desastres.net Internet Source	<1 %
16	"Desarrollo de un modelo clínico-radiómico de aprendizaje automatizado, para la predicción	<1 %

de respuesta a la quimioterapia neoadyuvante en pacientes con cáncer de mama.", Pontificia Universidad Catolica de Chile, 2024

Publication

17	bde.es Internet Source	<1 %
18	ri.ues.edu.sv Internet Source	<1 %
19	dspace.ups.edu.ec Internet Source	<1 %
20	repositorio.uchile.cl Internet Source	<1 %
21	sedici.unlp.edu.ar Internet Source	<1 %
22	www.nuskin.com Internet Source	<1 %
23	www.repositorio.usac.edu.gt Internet Source	<1 %

Exclude quotes On

Exclude matches Off

Exclude bibliography On

Algoritmo para la Optimización de Análisis en Ecografías Mamarias para la Detección Temprana del Cáncer de Mama en Entornos con Recursos Limitados

GRADEMARK REPORT

FINAL GRADE

GENERAL COMMENTS

/20

PAGE 1

PAGE 2

PAGE 3

PAGE 4

PAGE 5

PAGE 6

PAGE 7

PAGE 8

PAGE 9

PAGE 10

PAGE 11

PAGE 12

PAGE 13

PAGE 14